Guía de exposición y demostración

Ruben Vigil · 4 de noviembre de 2026

Guion de apoyo para las 12 diapositivas. Ajustar la duración al tiempo indicado por el docente; no hay un tiempo de exposición impuesto por este documento.

Primera parte: problema, datos y metodología

1. Machine Learning para planificar entregas

Presentar el objetivo: usar datos reales para estimar duración y riesgo. La entrega, repartidores y efectivo son simulados; no es una operación comercial desplegada.

2. Qué problema resuelve el prototipo

Separar predicción de reglas. El modelo no calcula precios ni decide el repartidor. Esas decisiones se prueban con políticas explícitas y ejemplos, sin presentarlas como resultados de ML.

3. Arquitectura que ya funciona

Explicar por qué FastAPI y Spark no compiten: FastAPI recibe HTTP; scikit-learn predice; Pandas/Dask/PySpark procesan datos offline. MongoDB guarda operación; S3 guarda archivos. La API pública en AWS todavía no está desplegada.

4. Datos observados y separación temporal

Distinguir intentos de pedidos. La purga evita entrenar con entregas que todavía no se conocían al cortar. El dataset es chino y de ventana corta; no representa mediciones de El Salvador.

5. Pandas, Dask y PySpark: resultados equivalentes

Los tiempos son resultados previos conservados, no estimaciones. Dask usó dos trabajadores y Spark se ejecutó localmente con dos hilos. Se separan arranque y pipeline. La normalización de CSV no demuestra identidad de escritores originales.

6. Qué aprenden los dos modelos actuales

La distancia aproximada hace que ETA responda al recorrido. El clasificador aprende la relación entre contexto, plazo y retraso observado. No usa tráfico, vehículo o tiempos de recogida posteriores para cotizar.

Guion: resultados y cierre

7. Resultado de duración: error menor

MAE significa error absoluto medio, no promesa de error máximo. El RF espacial tuvo un MAE de test apenas menor, pero no cambiamos al ganador mirando test. R^2 no equivale a porcentaje de exactitud.

8. Resultado de retraso: mejora modesta

La prevalencia de retraso es aproximadamente 15%, por eso acertar muchos pedidos puntuales no basta. El modelo supera la referencia constante, pero no debe venderse como garantía o probabilidad calibrada localmente.

9. También se entrenó una red neuronal pequeña

Mostrar que la parte académica compara diferentes algoritmos y una MLP real. El anexo contiene la curva de 30 épocas de validación y la elección de siete. No confundir este experimento temporal con la revisión geográfica.

10. Demo: del recorrido al efectivo registrado

Usar la guía de exposición para arrancar. Cambiar a plazo 45 en el recorrido de 5.56 km: el riesgo registrado pasa a 32.89%, con igual ETA. La demo usa IDs nuevos y genera un recibo, sin viajes o cobros reales. Si no hay conexión, explicar que se muestran resultados guardados.

11. Límites que deben quedar claros

La aclaración oficial de Meituan permite distancias relativas con coordenadas desplazadas; la codificación 1e6 sigue siendo inferencia explícita. Explicar límites demuestra rigor y separa un prototipo académico de un servicio comercial.

12. Aporte alcanzado y siguiente validación

Cerrar con el aporte real, sin prometer producción. Las fuentes, detalles y evidencia se entregan en Word/PDF y ZIP. Abrir preguntas y distinguir el trabajo implementado de Next.js y despliegue todavía pendientes.

Demostración: preparación y recorrido

Antes de empezar

Abrir Presentacion_Defensa.pptx o su PDF y tener a mano el reporte técnico, el anexo y el paquete de entrega. Confirmar que el equipo tenga Docker y perfil AWS de lectura configurados. No mostrar el contenido de .env o las credenciales durante la exposición.

Desde la raíz del repositorio, en la misma terminal:

```
export DELIVERY_RUN_UID="$(id -u)"
export DELIVERY_RUN_GID="$(id -g)"
export DELIVERY_AWS_CONFIG_DIR="$HOME/.aws"
DELIVERY_DEMO_ENABLED=1 docker compose -f compose.yaml -f compose.s3.yaml up --build -d --wait
```

Secuencia sugerida en vivo

• Abrir http://127.0.0.1:8000/docs y seleccionar POST /predict/delivery.

• Usar fecha 2022-10-22T18:00:00Z, origen 0.0/0.0, destino 0.0/0.01 y plazo 30.0. Son coordenadas ilustrativas, no negocios reales.

• Cambiar solo la longitud destino a 0.05: comparar duración y riesgo. Luego cambiar plazo a 45.0: comparar riesgo para el mismo recorrido.

• Ejecutar python3 scripts/demo_delivery.py. Mostrar modelo, duración, riesgo y estado final; las tarifas siguen siendo de ejemplo.

• Abrir data/reports/presentation/demo_result.json: comprobar delivery_prediction.model_source=s3, pedido entregado y último evento de efectivo entregado_al_operador.

Resultados guardados para comparar

Escenario ilustrativo	ETA registrada	Riesgo registrado
1.11 km / plazo 30	23.10 min	17.67%
5.56 km / plazo 30	45.38 min	70.60%
5.56 km / plazo 45	45.38 min	32.89%

Cada ejecución genera IDs nuevos y guarda un recibo. No se mide un viaje físico ni se realiza un cobro. El comando CLI usa la hora actual; sus cifras pueden diferir de los escenarios con fecha fija. El health antiguo describe v1; verificar v2 mediante /predict/delivery.

Preguntas frecuentes y plan de respaldo

¿Qué parte es Machine Learning?

Dos modelos predicen duración y probabilidad de retraso. Precios, elegibilidad de vehículos, rutas y registro de efectivo son reglas configurables.

¿Por qué FastAPI y no Spark?

FastAPI recibe HTTP y scikit-learn ejecuta los modelos. Spark se usó para demostrar procesamiento offline equivalente; no hace falta para una predicción pequeña por solicitud.

¿Qué calcula Haversine?

Una separación esférica aproximada entre coordenadas. No sigue calles ni estima tráfico. Es una fórmula usada para construir una entrada del modelo y aplicar reglas.

¿Por qué no se eligió el menor MAE de test?

Se seleccionó por validación temporal antes de evaluar test. Elegir después por el mejor test alteraría la función de ese conjunto de evaluación.

¿Esto ya funciona para El Salvador?

La demo funciona, pero las métricas provienen de China. Falta validación local. La escala de coordenadas es inferida y el riesgo tiene discriminación modesta.

¿Dónde están los pesos y la base?

Los pesos versionados están en S3 y se descargan/verifican al inicio; luego se usan en memoria. La demo usa MongoDB local; Atlas es la alternativa cloud verificada.

¿Qué falta para operación pública?

Datos/evaluación locales, calibración del riesgo, interfaz, controles de acceso, presupuesto, rol IAM y validación del despliegue. No se afirma haber desplegado la API en AWS.

Si falla la demo o no hay conexión

Si la API ya cargó los pesos, la inferencia no vuelve a descargarlos por petición. No reiniciar innecesariamente. Ante un 503 o conexión ausente, mostrar el PDF y el recibo/evidencias guardados e identificarlos expresamente como resultados previos. No presentar una captura o salida guardada como si fuera una llamada nueva.

Para detener conservando los datos: docker compose -f compose.yaml -f compose.s3.yaml down. Mantener las variables exportadas de la preparación; evitar --volumes si se desea conservar la demo.