Machine Learning para planificar entregas

Duración del envío y riesgo de retraso

Prototipo de Asistente de Delivery Económico

Datos reales

Meituan / INFORMS

Dos modelos

ETA + probabilidad

Demo integrada

FastAPI · MongoDB · S3

Qué problema resuelve el prototipo

Preguntas para Machine Learning

¿Cuánto podría tardar el envío?

¿Qué probabilidad hay de superar el plazo indicado?

Preguntas para reglas explícitas

¿Qué tarifa de ejemplo resulta?

¿Qué vehículo cumple los límites?

¿Cómo registrar entrega y efectivo?

Las tarifas, límites y datos de la demo son configuración simulada; no se aprenden de etiquetas inventadas.

Arquitectura que ya funciona

Descarga verificada al inicio; inferencia en memoria. Sin reentrenar por petición.



ECS/Fargate: API activa

Atlas + S3 verificados

Next.js: pendiente

Datos observados y separación temporal

654,343 intentos

Fuente operacional original

546,281 pedidos

Cohorte inmediata completada

409,083

Entrenamiento

136,799

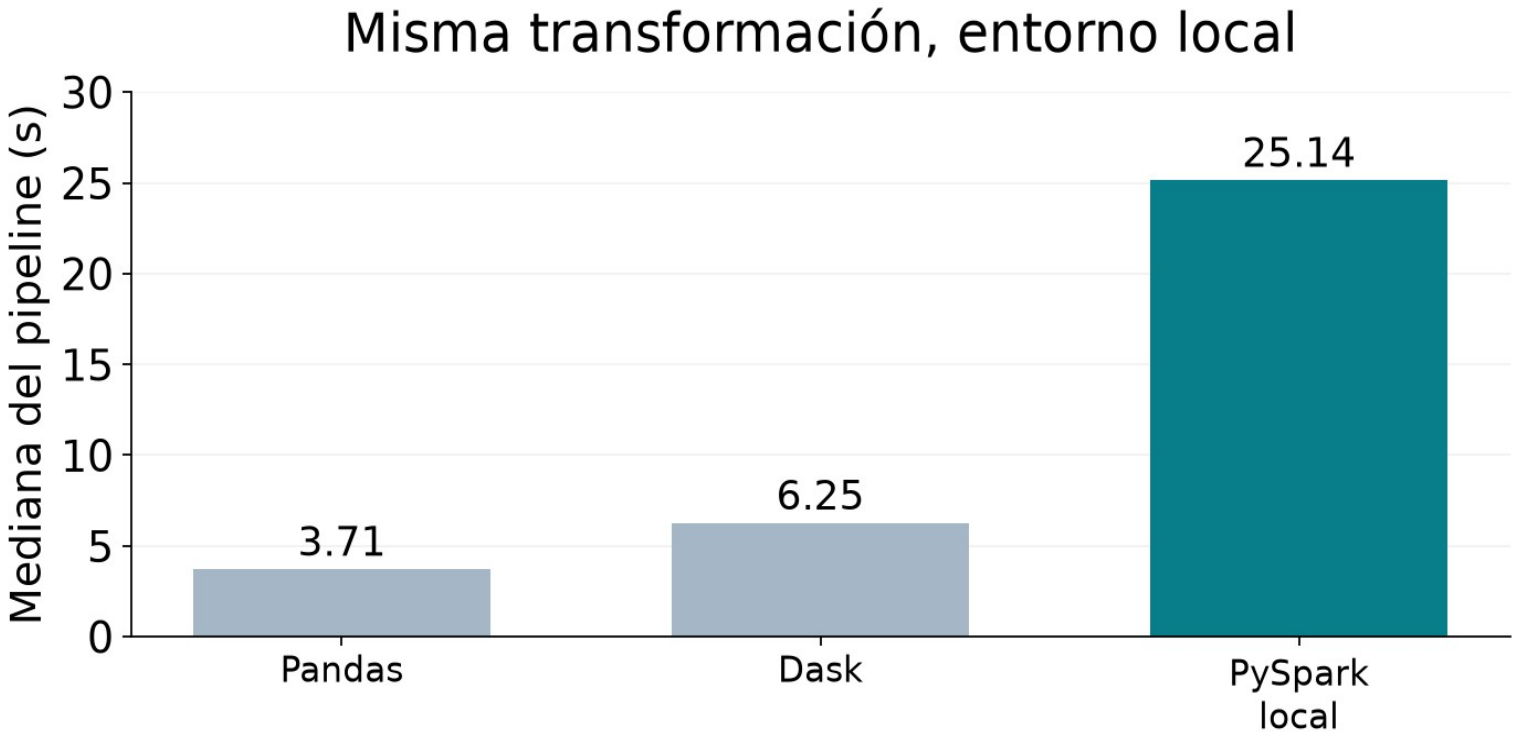
Prueba temporal

399

Purga de etiquetas futuras

Se excluyen casos ambiguos y reservas. Los tiempos se derivan de eventos observados.

Pandas, Dask y PySpark: resultados equivalentes



Qué se comprobó

Mismos valores

546,281 pedidos

Tres mediciones locales

Pandas fue más rápido en este volumen. No es una comparación de clústeres ni una conclusión universal.

Qué aprenden los dos modelos actuales

Duración del envío

Distancia origen–destino

Hora y día UTC

Salida: minutos creación–entrega

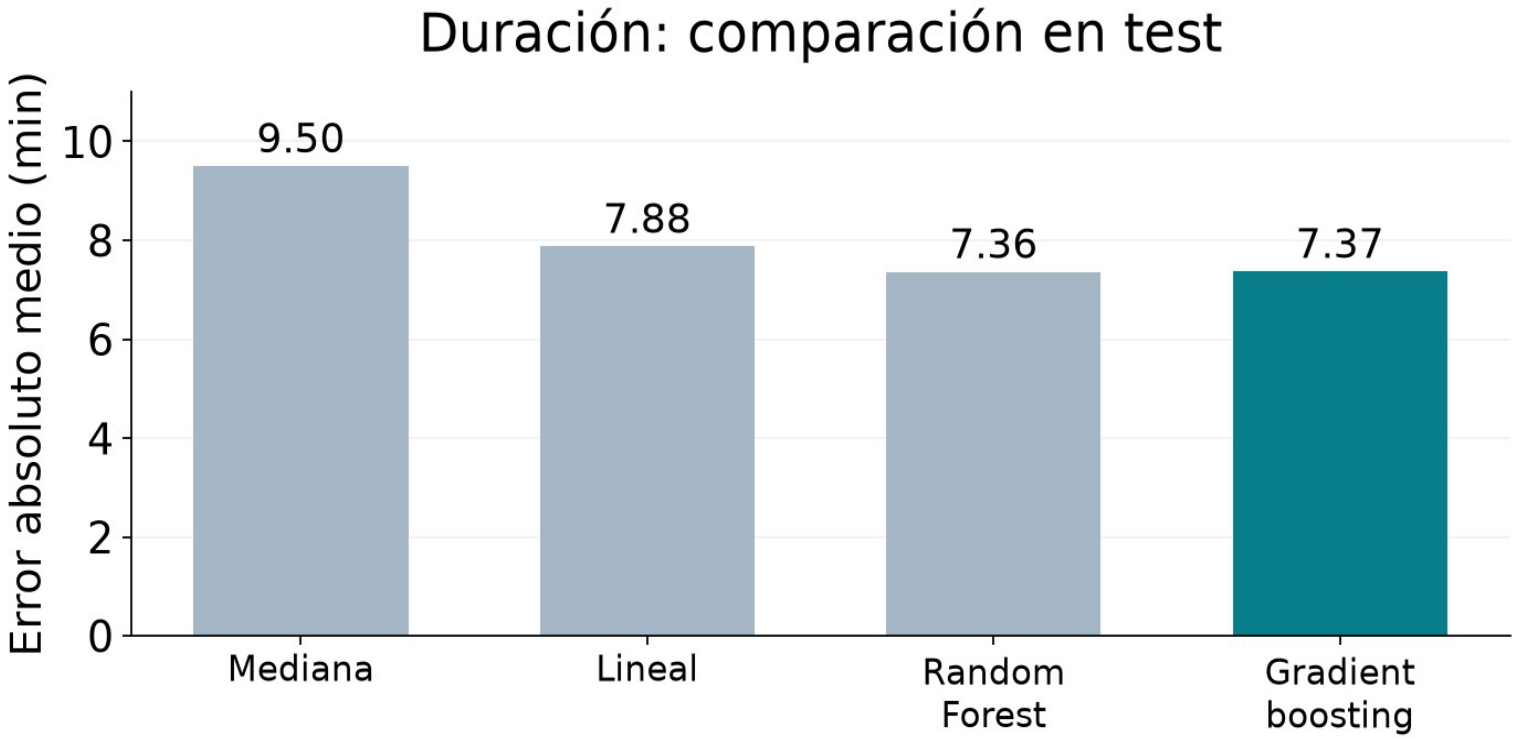
Riesgo de retraso

Mismas entradas + plazo

Salida: probabilidad de entregar después del plazo

Selección con tres folds temporales. Llegada observada: etiqueta, nunca entrada del predictor.

Resultado de duración: error menor



7.37 min

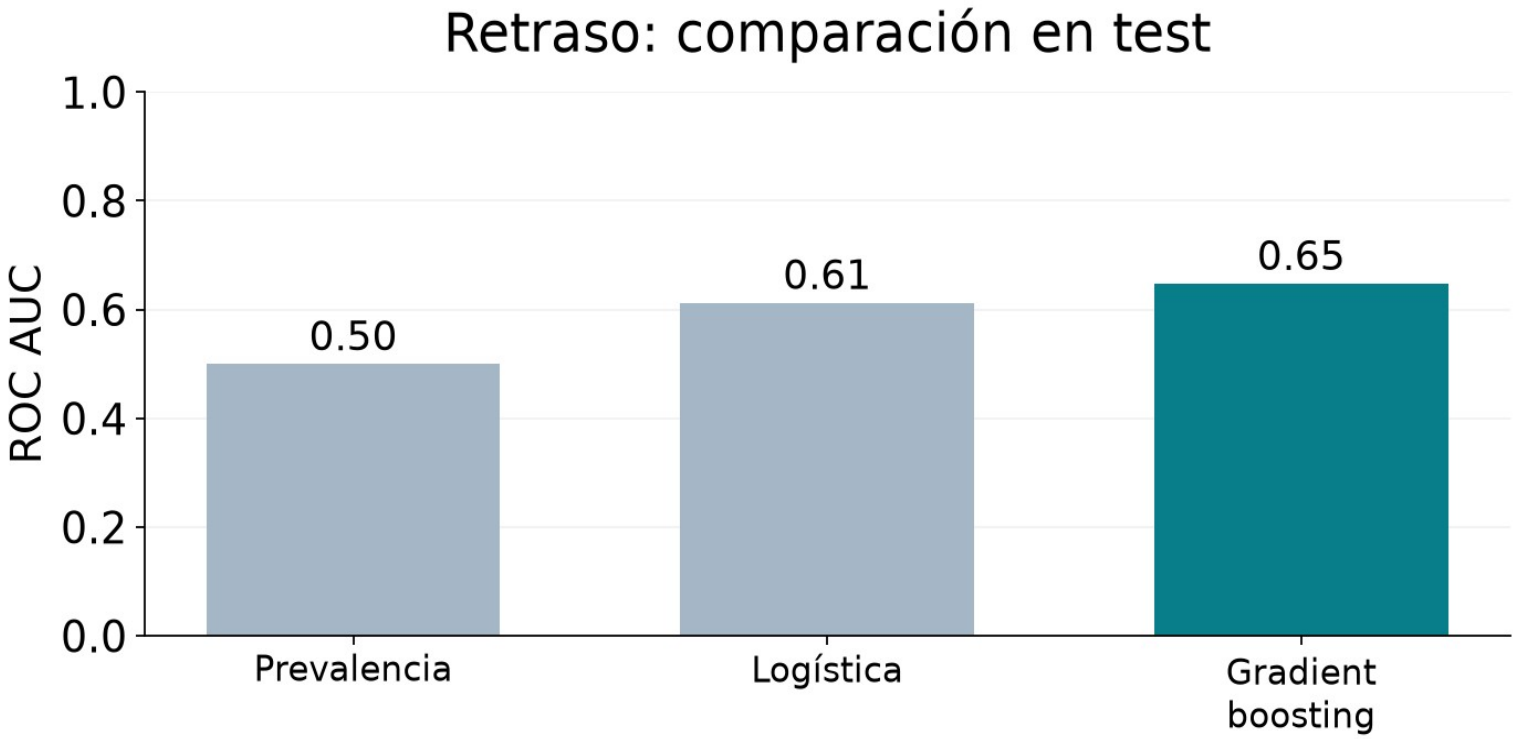
Error absoluto medio

$R^2 = 0.358$

≈19.2% menos MAE que la versión temporal

Gradient boosting se eligió por validación. El test ya observado convierte esta revisión en exploratoria.

Resultado de retraso: mejora modesta



0.648

ROC AUC

Referencia: 0.500

Log-loss: 0.404

Brier: 0.123

ROC AUC no es 64.8% de aciertos. No se ha demostrado calibración para El Salvador.

También se entrenó una red neuronal pequeña

4 entradas
Calendario cíclico

→

16 neuronas
ReLU

→

8 neuronas
ReLU

→

1 salida
Minutos

225 parámetros · 7 épocas seleccionadas por CV

Experimento temporal v1: MAE test 9.12 min.

No se reentrenó esta MLP con distancia; no es uno de los dos modelos vigentes.

Demo: predicción AWS y flujo local

1. Swagger: elegir ejemplo

2. Datos simulados en Atlas

3. Efectivo: demo local

1.11 km / plazo 30

ETA 23.10 min · riesgo 17.67%

5.56 km / plazo 30

ETA 45.38 min · riesgo 70.60%

AWS: predicción y CRUD

Local: entrega y efectivo

model_source = s3

Valores guardados de ejemplos previos; las consultas en vivo calculan nuevas salidas.

Límites que deben quedar claros

Datos y evaluación

Datos de China, ventana corta

Solo pedidos completados

Test reutilizado

Sin validación en El Salvador

Geometría y operación

Escala 1e6 inferida

Distancia sin calles o tráfico

Riesgo no calibrado localmente

Vehículos y efectivo simulados

Los resultados no acreditan ahorro, ROI o tiempos distintos por bicicleta y moto.

Aporte alcanzado y siguiente validación

ETA por recorrido

Distancia y calendario

MAE menor que v1

Riesgo por plazo

Clasificación aprendida

Mejora sobre referencia

API en AWS

Fargate + Atlas

Modelos desde S3

Siguiente: interfaz Next.js, datos locales y evaluación independiente.

Fuentes: Meituan / INFORMS; reporte técnico y anexo de evidencias del proyecto.