Despliegue AWS: estado y arquitectura

Asistente de Delivery Económico · Ruben Vigil · 4 de noviembre de 2026

Infraestructura creada con autorización de Ruben: ECS/Fargate, ECR, red, roles, logs y secreto. Atlas y S3 se reutilizan. El contenedor espera acceso a Atlas; la API y sus modelos todavía no se han validado desde AWS.



Fargate ya ejecuta una tarea. Imagen publicada en ECR con commit 35c6030; Atlas y S3 ya existían. La demo local se conserva.

Configuración desplegada

Elemento	Decisión
Región	us-east-1, junto al bucket existente.
Cómputo	ECS con Fargate Linux x86_64: una tarea de 0.5 vCPU y 2 GiB, capacidad funcional todavía pendiente de validar. Sin instancias EC2 administradas por el proyecto.
Red de demo	Subred pública e IPv4 de tarea; acceso limitado a la IP del presentador. Sin ALB ni NAT Gateway en esta primera demo. IP variable al reemplazar la tarea.
Aplicación	Imagen Docker existente con FastAPI; descarga v2 desde S3 al iniciar y predice en memoria.
Datos	Atlas Free existente; S3 ml-kodigo-resources sin recrear bucket, cambiar políticas o subir registros del dataset.
Acceso	Rol de tarea: lectura del modelo S3. Rol de ejecución: ECR, logs y secreto Atlas. Credenciales en Secrets Manager, fuera de imagen y Git.

Atlas permitirá solo la IPv4 de salida vigente de la tarea (/32); habrá que actualizarla al reemplazarla antes de validar disponibilidad. Next.js se incorporará después. Spark y entrenamiento siguen offline. Esta demo no ofrece endpoint estable, HTTPS ni alta disponibilidad.

Costo aproximado y pasos siguientes

Orden de magnitud: USD 25–30 al mes de base para una tarea de 0.5 vCPU y 2 GiB encendida 730 horas, incluida una IPv4 pública. Uso solo durante la exposición reduce el cómputo. Referencias consultadas el 4 de noviembre de 2026; sin asumir créditos gratuitos.

Concepto	Aproximación mensual
Fargate Linux x86: CPU + memoria	USD 21.27
Una IPv4 pública	USD 3.65
Base, sin servicios variables	USD 24.92

ECR, logs, Secrets Manager, S3, transferencia e impuestos se cobran aparte según uso. Atlas conserva Free. No incluye balanceador ni NAT Gateway; añadirlos o incorporar Next.js requiere revisar esta estimación. Es una referencia académica, no una cotización.

Implementación posterior

• Terraform aplicado: 19 altas, cero cambios/bajas. Cuenta/región y alcance revisados antes del apply. Revisión activa administrada por pipeline.

• Permitir la IPv4 /32 de la tarea activa en Atlas. La demo espera sin límite para conservar tarea/IP durante ese paso; una caída puede cambiarla.

• Imagen y secreto publicados sin exponer la URI. El proceso espera Atlas con la misma tarea/IP antes de iniciar la API.

• CI aprobada y entrega manual desde main protegida con aprobación. OIDC/IAM declarados; activación y validación cloud pendientes de autorización.

Fuentes oficiales de referencia

AWS Fargate: funcionamiento y administración de servidores

AWS Fargate: precios de referencia us-east-1

Amazon ECS: red pública y acceso a internet

Amazon VPC: precio de direcciones IPv4 públicas

Estado real: 19 recursos creados, secreto cargado y una tarea ejecutándose. OIDC/ECR y revisión ECS verificados; plan posterior sin cambios. Pendiente: permitir la IP de Fargate en Atlas y comprobar API, modelos y persistencia. Bucket S3 sin modificar.