REPORTE TÉCNICO

Asistente de Delivery Económico

Arquitectura, datos reales y modelos predictivos

Autor: Ruben Vigil

Fecha: 4 de noviembre de 2026

Resumen ejecutivo

El proyecto es un prototipo académico que simula la gestión de entregas y utiliza Machine Learning para estimar su duración y el riesgo de superar un plazo prometido. Integra FastAPI, MongoDB, Amazon S3 y Docker; la API ya se ejecuta en ECS/Fargate con modelos S3 y persistencia Atlas verificados; la interfaz Next.js local muestra pedidos, predicciones y estados; incluye demo individual, agrupada y efectivo.

La versión vigente ejecuta dos modelos entrenados con datos reales de Meituan. La distancia origen–destino y el calendario alimentan la estimación de duración; el plazo prometido se añade al clasificador de retraso. Los precios, límites de vehículos y movimientos de efectivo son reglas y escenarios simulados, no resultados aprendidos.

Duración: MAE	Retraso: ROC AUC	Evaluación
7.37 minutos	0.648	136,799 pedidos de test

El error de duración mejora respecto de la versión temporal anterior, pero los resultados siguen siendo experimentales: el test se reutilizó, la discriminación del riesgo es modesta y no existe validación para El Salvador.

Contenido del reporte

1. Arquitectura y responsabilidades
2. Datos, procesamiento y variables
3. Diseño de los experimentos
4. Resultados y comparación
5. Demostración y evidencia de ejecución
6. Limitaciones y conclusiones
7. Reproducción y referencias

1. Arquitectura y responsabilidades

La API recibe solicitudes HTTP, valida los datos y coordina servicios. El código se organiza en routers, schemas, models, services, repositories, database, ml y storage. El entrenamiento ocurre fuera de la API.

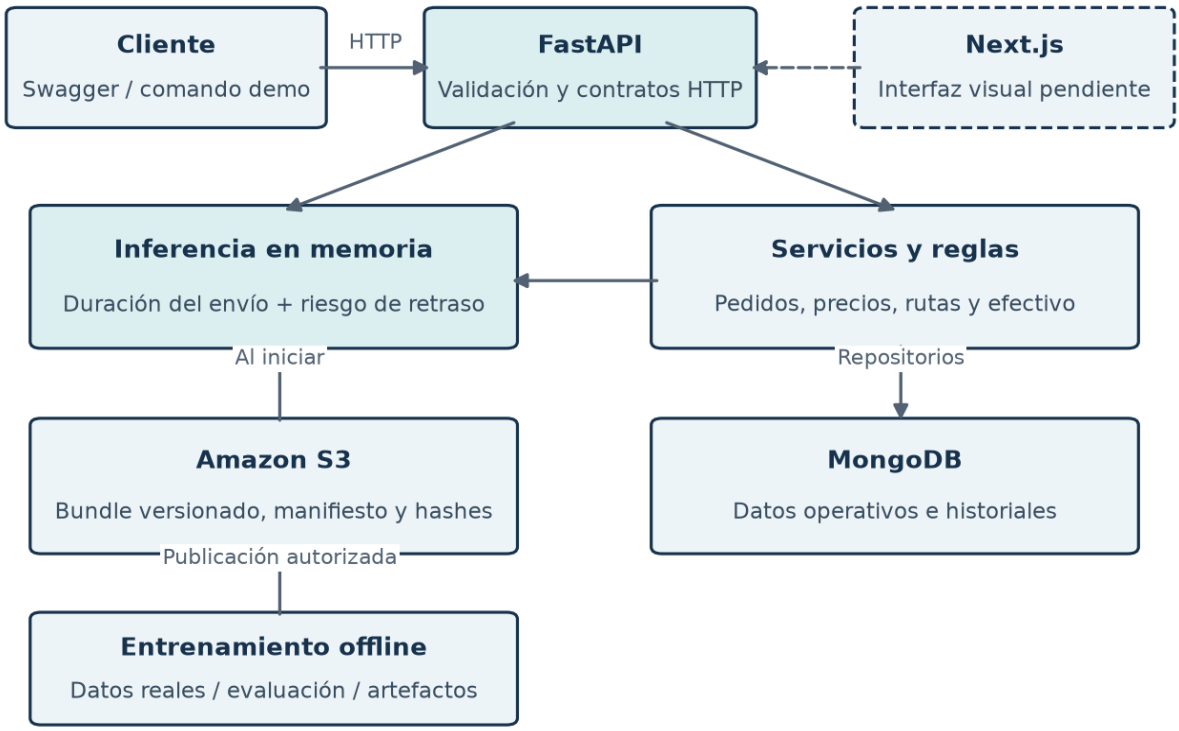


Figura 1. Componentes actuales y flujo de datos. La conexión discontinua corresponde a la integración visual en AWS pendiente; la interfaz local ya está implementada. Diagrama elaborado para este reporte.

Componente	Función
FastAPI y servicios	Consultar predicciones, registrar pedidos y ejecutar el recorrido simulado.
MongoDB	Conservar negocios, repartidores, pedidos, asignaciones y efectivo con sus historiales.
Amazon S3	Guardar bundles versionados y evidencia; recuperar los pesos al iniciar.
Docker Compose	Reproducir API y réplica MongoDB local con volumen persistente.
Entrenamiento offline	Preparar datos, comparar algoritmos y producir artefactos evaluados.

El bucket existente es ml-kodigo-resources, en us-east-1. La demo completa documentada aquí usa MongoDB local. Se complementó con API ECS/Fargate: predicción S3 y CRUD Atlas verificados; ver documento AWS adjunto.

2. Datos, procesamiento y variables

La fuente seleccionada es el conjunto operacional de Meituan publicado para el desafío INFORMS TSL. La revisión de origen está fijada por hash; se conserva licencia y reconocimiento de uso académico no comercial. No se publican registros del dataset en Git ni en el bucket del proyecto. [1, 2]

Etapa	Cantidad	Interpretación
Fuente original	654,343	Registros de intentos de entrega; no todos son pedidos diferentes.
Pedidos originales	568,546	Pedidos identificados en la auditoría.
Cohorte procesada	546,281	Pedidos inmediatos completados, inequívocos y con cronología válida.
Entrenamiento	409,083	Etiquetas disponibles antes del corte temporal.
Prueba	136,799	Pedidos creados desde el inicio del test.
Purga	399	Pedidos anteriores cuyo resultado no estaba disponible al cortar.

Objetivos aprendidos

Duración: minutos transcurridos entre la creación del pedido y su entrega observada. La etiqueta se calcula como (arrive_time − platform_order_time) / 60; no se genera mediante velocidades o tiempos supuestos.

Retraso: indicador de que la entrega observada ocurre después del plazo prometido registrado. La etiqueta es arrive_time > estimate_arrived_time. El plazo se transforma en minutos desde la creación y se usa como entrada conocida del escenario.

Preparación y control de información futura

Pandas materializa una fila elegible por pedido, consolida intentos y comprueba identificadores, tipos y cronología. Dask y PySpark local demuestran transformaciones equivalentes y se comparan bajo condiciones documentadas. Estas herramientas se usan offline, no para atender cada petición de la API.

Los modelos reciben calendario UTC y distancia; el clasificador añade el plazo. La llegada observada se usa solamente para construir etiquetas. No se suministran IDs, información posterior de recogida/aceptación, vehículo o preparación sin instante acreditado.

Las coordenadas están desplazadas de forma uniforme según la aclaración del editor. La conversión entera mediante divisor 1e6 es una inferencia de codificación documentada. La distancia esférica aproxima separación; no representa recorrido por calles. [2]

3. Diseño de los experimentos

Separación temporal y prevención de fuga

La frontera de prueba es el 23 de octubre de 2022 a las 00:00 UTC. Solo se entrena con resultados observados antes del corte. Los 399 pedidos creados antes pero aún abiertos se purgan para impedir que una etiqueta futura entre en entrenamiento.

La selección utiliza tres folds temporales por día y respeta la disponibilidad de etiquetas. El preprocesamiento aprendido se ajusta dentro de cada fold. La ETA se selecciona por menor error absoluto medio de validación; el riesgo, por menor log-loss.

Experimento	Entradas y candidatos	Uso de los resultados
Versión temporal anterior	Hora/día; baseline, regresión lineal, Random Forest, LinearSVR y MLP pequeña.	Comparación académica conservada; no es la ETA geográfica vigente.
Duración vigente	Hora/día cíclicos y distancia; mediana, lineal, Random Forest y gradient boosting.	Predecir minutos creación–entrega para un recorrido.
Riesgo vigente	Mismas variables más plazo; prevalencia, logística y gradient boosting.	Probabilidad estimada de superar el plazo indicado.

Selección y evaluación

Ambos modelos seleccionados pertenecen a HistGradientBoosting. Sus parámetros se fijaron antes de esta comparación. El conjunto de test no se usa para cambiar al ganador: Random Forest obtuvo un MAE de test ligeramente menor, pero gradient boosting se mantuvo por su resultado de validación.

La MLP pertenece al experimento temporal previo. No se reentrenó con distancia para la revisión vigente y no se presenta como una candidata equivalente de esa revisión.

Alcance de la comparación

El test ya había sido observado al evaluar la versión anterior. Por ello, la revisión actual se considera exploratoria; no constituye validación externa ciega ni demuestra transferencia de desempeño al entorno salvadoreño.

La evidencia conserva particiones, hashes de datos, métricas por fold, selección y evaluación de todos los candidatos. El código permite reproducir el experimento en un directorio nuevo sin sobrescribir el bundle anterior.

4. Resultados y comparación

Resultados observados sobre 136,799 pedidos de test. El modelo seleccionado se identifica con un asterisco; la selección se realizó con validación temporal, no por esta tabla.

Modelo de duración	MAE (min)	RMSE (min)	R^2
Mediana	9.5012	12.5625	-0.0381
Regresión lineal	7.8752	10.3379	0.2970
Random Forest	7.3640	9.7612	0.3733
Gradient boosting *	7.3697	9.8790	0.3581

Modelo de retraso	Log-loss	Brier	ROC AUC	AP
Prevalencia constante	0.4222	0.1273	0.5000	0.1497
Regresión logística	0.4150	0.1257	0.6126	0.1979
Gradient boosting *	0.4039	0.1227	0.6477	0.2376

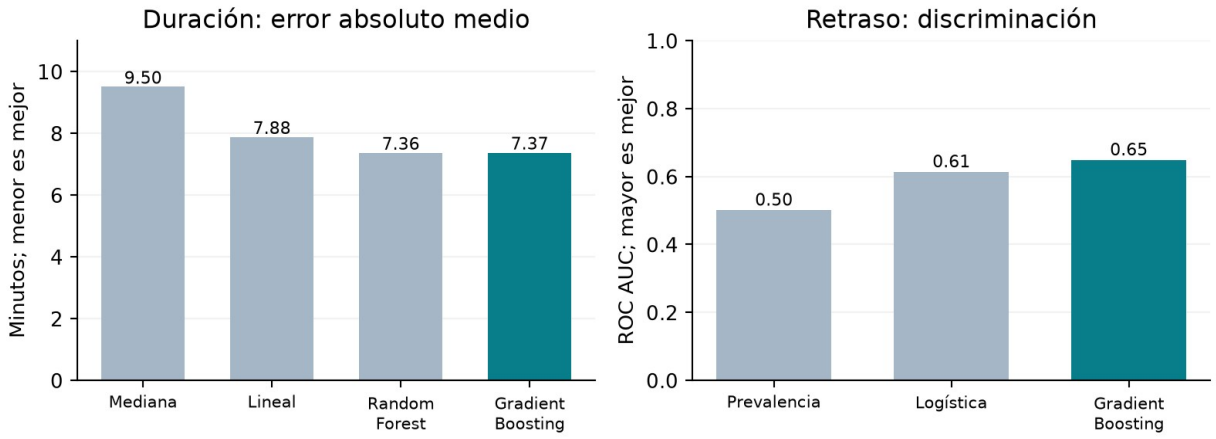


Figura 2. Comparación de candidatos. Datos leídos directamente de evidence.json del bundle vigente.

ETA: el MAE disminuye aproximadamente 19.2% respecto del Random Forest temporal anterior (9.125362 min). R^2 0.358 indica capacidad explicativa parcial; no equivale a 35.8% de exactitud. Los errores todavía son relevantes.

Riesgo: la prevalencia de retraso es 14.97%; ROC AUC 0.648 mejora la referencia 0.5, con discriminación modesta. Menor log-loss/Brier es mejor. AP corresponde a average precision; el campo pr_auc del archivo no es integración trapezoidal de la curva PR.

5. Demostración y evidencia de ejecución

La demostración combina los servicios existentes y escribe registros identificados como demo en MongoDB. Los modelos se recuperan de S3 al arrancar: el manifiesto, los archivos, sus hashes, la versión y el entorno se verifican antes de cargar los pesos en memoria.

Recorrido completo

- Solicitud estructurada con negocio, repartidor, origen y destino simulados.
- Predicción de duración y riesgo; cálculo del precio mediante reglas explícitas.
- Aceptación para ese recorrido simulado, confirmación y reserva del repartidor.
- Recogida y entrega; registro separado del cobro y entrega del efectivo al operador.
- Liberación del repartidor y conservación del recibo, mensajes e historiales.

Consultas ilustrativas a los modelos entrenados

La fecha se mantiene fija: 22 de octubre de 2022, 18:00 UTC. Las coordenadas y plazos son escenarios de consulta, no viajes observados. Las salidas se registraron en una comprobación HTTP real.

Distancia aprox.	Plazo (min)	ETA (min)	Riesgo
1.11 km	30	23.10	17.67%
5.56 km	30	45.38	70.60%
5.56 km	45	45.38	32.89%

El recorrido modifica la estimación; para el mismo recorrido, cambiar el plazo modifica el riesgo. No se interpreta esta sensibilidad como una garantía o una validación de las rutas en El Salvador.

Estado final comprobado

Evidencia	Resultado
Origen de los pesos	S3; la respuesta informa model_source=s3.
Modelo	meituan-eta-risk-v2
Estado del pedido	entregado
Efectivo	entregado_al_operador
Carga inicial	Siete descargas; dos inferencias sin descargas adicionales.
Integridad y limpieza	Un hash incorrecto produjo 503; cliente y caché se cerraron.

La aceptación pertenece solo a la simulación. Los endpoints generales conservan sus requisitos. La reserva es transaccional, pero una interrupción del recorrido completo puede dejar pasos aceptados; no hay reanudación global automática.

6. Limitaciones y conclusiones

Validez de los modelos

Representatividad. Los datos corresponden a China y a un período corto. No existe validación de duración o riesgo con pedidos de El Salvador.

Cohorte. Se estudian pedidos inmediatos completados. El modelo no aprende probabilidad de cancelación o de entrega fallida.

Geometría. Hay desplazamiento de coordenadas y una escala 1e6 inferida. La distancia no incluye calles, circulación, tráfico o tiempos de espera medidos localmente.

Vehículos. No hay evidencia para afirmar tiempos distintos de bicicleta y motocicleta. Su elegibilidad se determina con reglas configurables.

Evaluación. El test fue reutilizado en la revisión. Se requiere una nueva evaluación independiente para sostener generalización.

Riesgo. La discriminación es modesta y no se ha demostrado calibración local. No se establece un umbral de decisión comercial ni se garantiza una entrega puntual.

Límites del sistema demostrado

WhatsApp, repartidores y efectivo están simulados. Las tarifas y costos del ejemplo no son precios observados ni recomendaciones de negocio. El sistema no acredita ahorro, rentabilidad, ROI o cobertura reales. La demo ejecuta eventos del simulador; no mide un viaje físico.

La API funciona en ECS/Fargate con S3 y Atlas; se verificaron predicción y CRUD, con acceso limitado a la IP del presentador. Next.js funciona localmente y aún no se publica en AWS. No hay HTTPS o alta disponibilidad, y la demo completa de efectivo documentada sigue siendo local.

Conclusión técnica

El aporte de Machine Learning es una estimación de duración sensible al recorrido y un clasificador de retraso sensible al plazo. La revisión mejora la referencia temporal y permite una demostración integrada con modelos reales. Su uso justificable sigue siendo académico; las mediciones actuales no sostienen una garantía comercial o transferencia directa a El Salvador.

7. Reproducción y referencias

Material que permite verificar el trabajo

Material	Contenido
Notebooks 01, 02 y 03	Preparación, comparación temporal ML/MLP y revisión de duración/riesgo.
Bundle meituan-eta-risk-v2	Dos pesos, metadatos, evidencia, tarjeta y hashes.
Recibo demo_result.json	Entradas simuladas, cotización, predicciones e historiales de ejecución.
Reporte de arranque S3	Carga única, integridad, cierre y comportamiento ante hash inválido.
Código y documentación	Recetas en README y módulos de adquisición, entrenamiento, API y persistencia.

La demo se ejecuta con Docker Compose y el complemento S3, un perfil de lectura configurado fuera de la imagen y el comando python3 scripts/demo_delivery.py. El README del repositorio contiene los pasos completos. En AWS se usan roles IAM; no se copian credenciales personales o pesos de la computadora. Swagger ofrece tres ejemplos y Atlas conserva 3 negocios, 2 repartidores y 3 pedidos ficticios con prefijo demo-expo-, separados del entrenamiento.

Entorno de los pesos: Python 3.12.14; scikit-learn 1.7.2; NumPy 2.5.4; SciPy 1.18.1; Pandas 2.3.3. La API comprueba estas versiones. El entrenamiento es offline y sus salidas se versionan sin sobrescribir artefactos anteriores.

Referencias y procedencia

[1] Meituan / INFORMS. Repositorio oficial del conjunto de datos y licencia.

[2] Meituan (2024). Aclaraciones del dataset, sección 2.1: coordenadas.

[3] INFORMS TSL. Presentación del desafío y acceso a la fuente.

[4] Implementación del proyecto y recetas reproducibles.

Evidencia cuantitativa: evidence.json y metadata.json del bundle meituan-eta-risk-v2. La publicación del bundle corresponde al commit 6a5a074. Las cifras de las tablas se generan desde esos archivos; los escenarios de la sección 5 proceden del registro HTTP guardado. No se reentrenó para producir este reporte.

Reconocimiento: This research was supported by data provided by Meituan.